Apport des optimisations V100 — sweep S0→S6

Qwen3.8-27B, Q6_K (23 Go, blob identique à la prod) · MTP n_max=3 · V100 seule (split none, main-gpu 0) · KV q8_0 · FA auto · llama-server binaire prod, -c 170000 · sans mmproj · 06/11/2026

Objectif

Mesurer l'apport de chaque optimisation (S1…S6) à 11 tailles de contexte (16k → point haut 167 568 tok), en decode et en prefill, MTP ON et OFF. Campagne purement mesuratoire — pas de recherche d'optimisation (S7/H2 exclus du périmètre).

Méthode de mesure

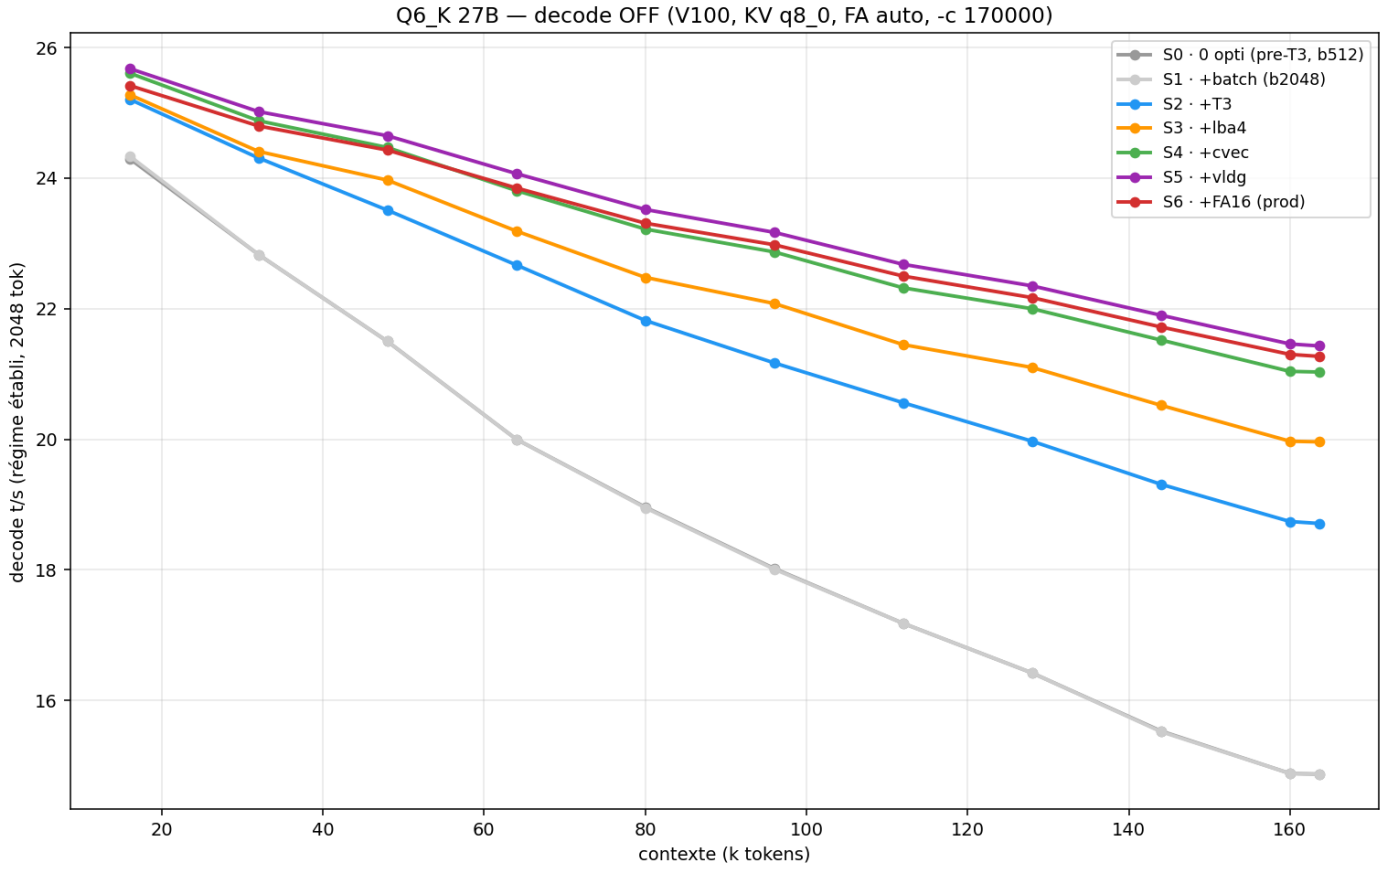
- R1 : 32 tok post-prefill froid (comparabilité rebench) ; R2 : 2048 tok → régime établi ; R3 : 32 tok chaud (diagnostique).
- Régime établi : OFF = médiane des fenêtres tg_3s ; ON = médiane des 6 DERNIÈRES fenêtres (plateau) — le warm-up MTP des ~1200 premiers tok (acceptance qui monte) est retiré, il creusait la médiane brute (surtout à 112k : 11–14 fenêtres lentes sur 15–26).
- Gates par run : SM ≥ 1150 MHz, température < 93 °C, prompt_tokens croisé (log serveur, ±0,5 %), md5 du .so vérifié.
- Anchor anti-drift S6/32k/MTP ON tous les ~20 runs, porte 5 % — aucun drift détecté sur les 154 runs (04:06 → 17:35).
- 4 re-mesures sur S6/off en haut de contexte (faux positifs du gate SM) — validées : le decode S6/off suit S5/off à −0,7…−1,0 % partout.

États mesurés (delta cumulé)

État	.so (hash)	env particulier	batch	Δ apporté
S0	t3 d2df07b8	FA_NO_VOLTA_SMALL=1	512	référence « 0 opti » (pre-T3)
S1	t3 d2df07b8	FA_NO_VOLTA_SMALL=1	2048	+batch 2048
S2	t3 d2df07b8	—	2048	+T3
S3	dual b014d026	—	2048	+lba4 (launch_bounds)
S4	cvec 723c0016	—	2048	+cvec K 128-bit
S5	vldg 87f85442	—	2048	+vldg V double-buffer
S6	**dual d4954502**	**FA_COMPACT_TMAX=8192**	**2048**	**+FA16 compact (prod actuel)**

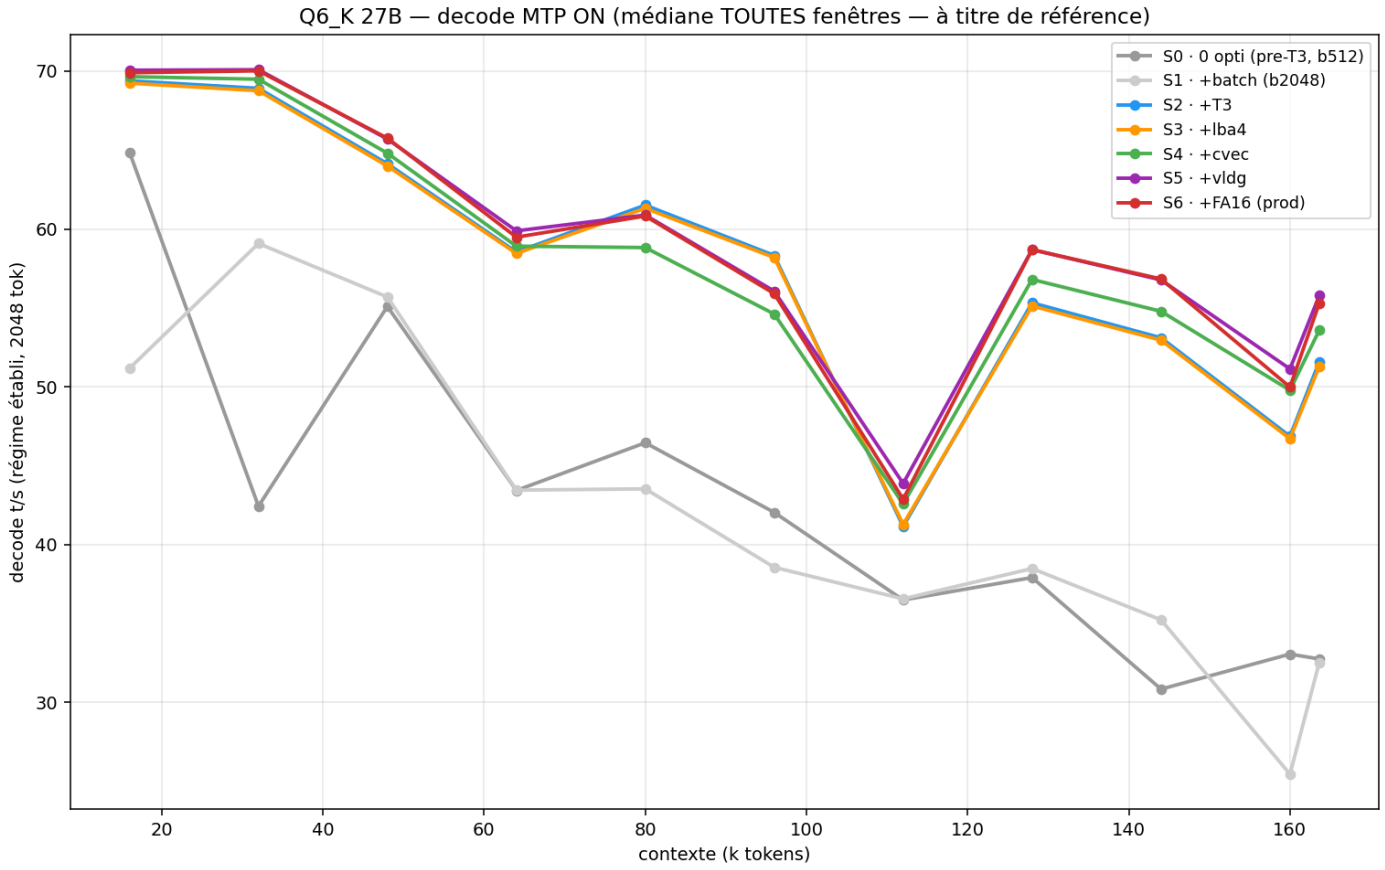
Env commun : Q6_W4R4=1, Q8_FATTN_TC=0, FIT_TARGET=1024. MTP ON : --spec-type draft-mtp --spec-draft-n-max 3 --spec-draft-backend-sampling + SPEC_MTP_DEFER_PROMPT=1 + shortlist.

Decode — MTP OFF (courbe de référence, propre)



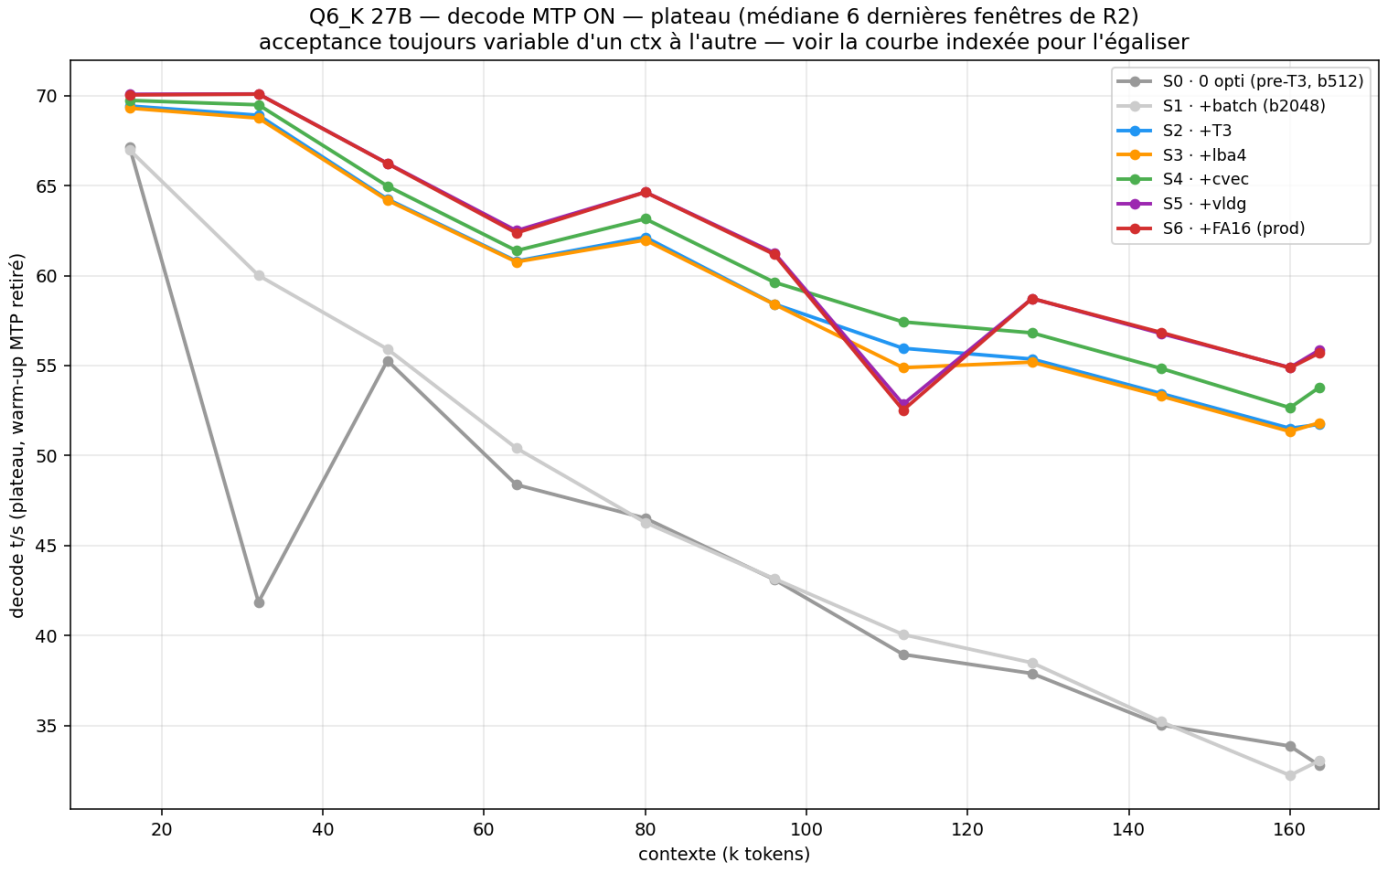
Ordre stable S0=S1 < S2 < S3 < S4 ≈ S5 ≈ S6 sur tout l'axe. Le saut S1→S2 (T3) est le plus gros bloc ; les paliers lba4/cvec/vldg prolongent la montée ; FA16 est neutre (−0,7…−1,0 %).

Decode — MTP ON (brut, médiane toutes fenêtres)



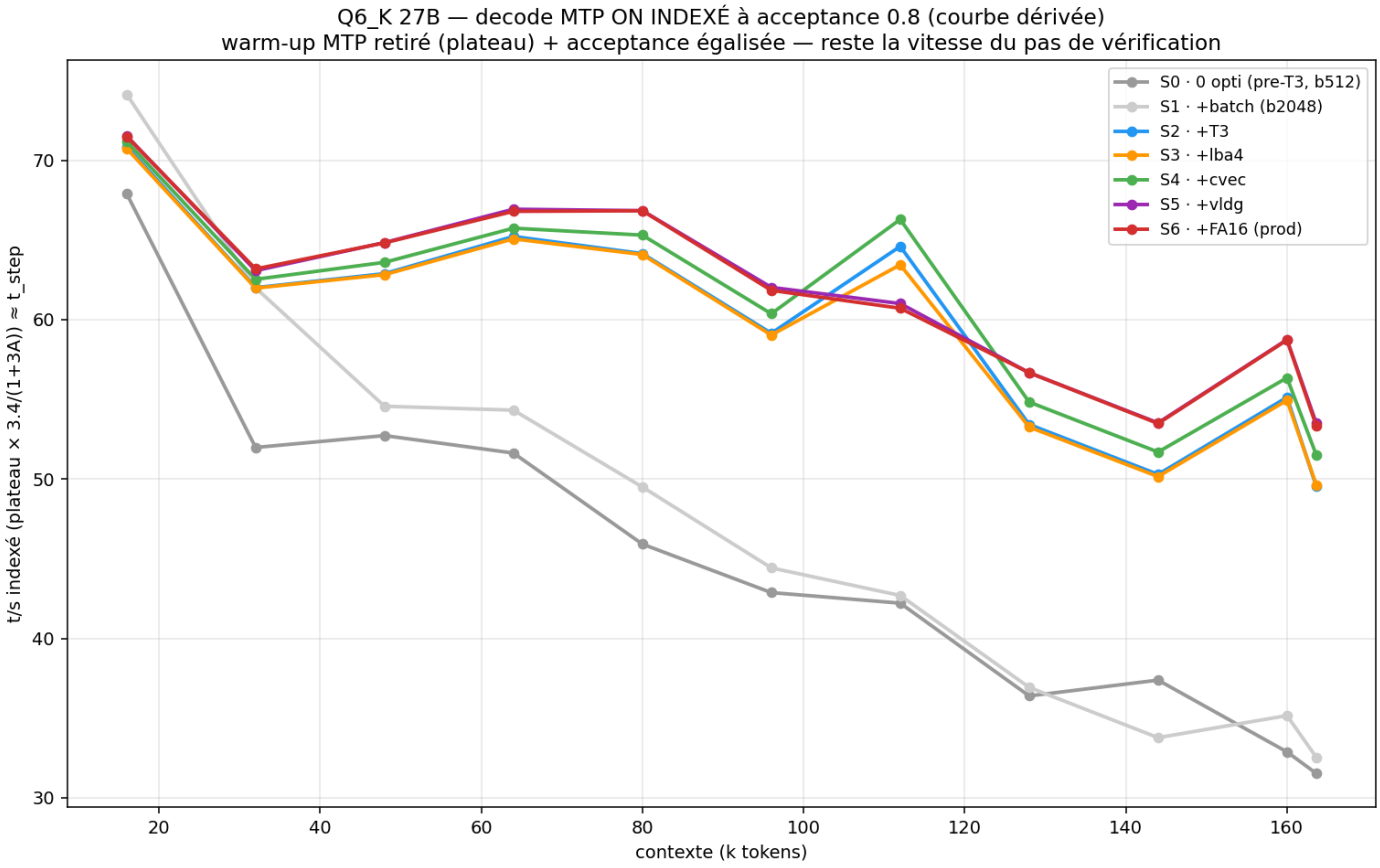
À titre de référence seulement. La médiane toutes fenêtres inclut le warm-up MTP (les ~1200 premiers tok générés sont lents, l'acceptance monte) — c'est lui qui creuse 112k (11–14 fenêtres lentes sur 15–26). Voir les 2 pages suivantes : plateau, puis indexé.

Decode — MTP ON en plateau (médiane 6 dernières fenêtres de R2)



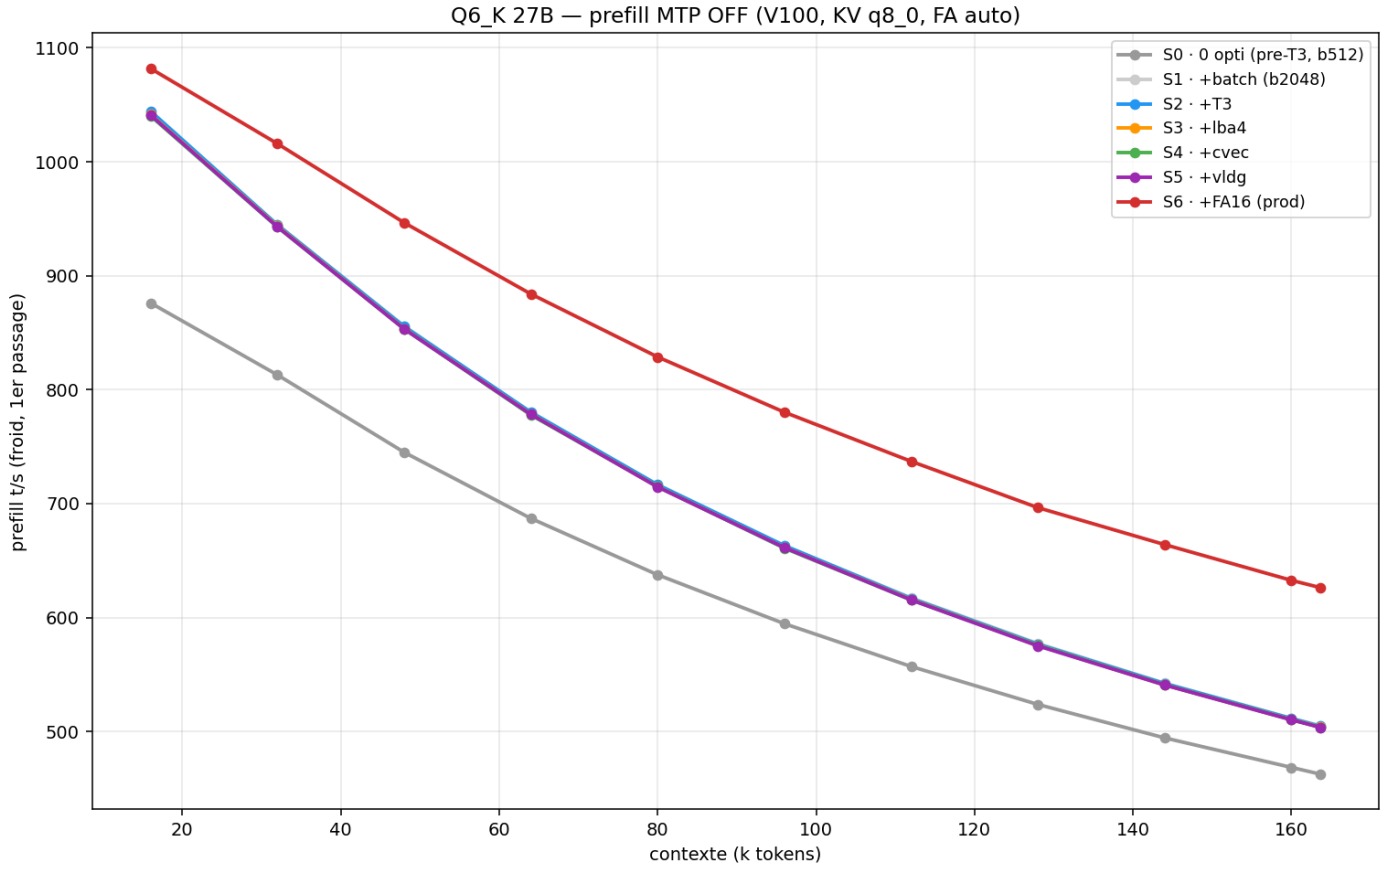
Même signal que le brut mais sans le warm-up MTP : le creux de 112k retombe (S6 : 42,9 → 52,5 t/s). Reste une ondulation d'acceptance (0,65 à 112k vs 0,84 à 128k) qui égalise la comparaison sur la page suivante.

Decode — MTP ON INDEXÉ à acceptance 0,8 (courbe dérivée)



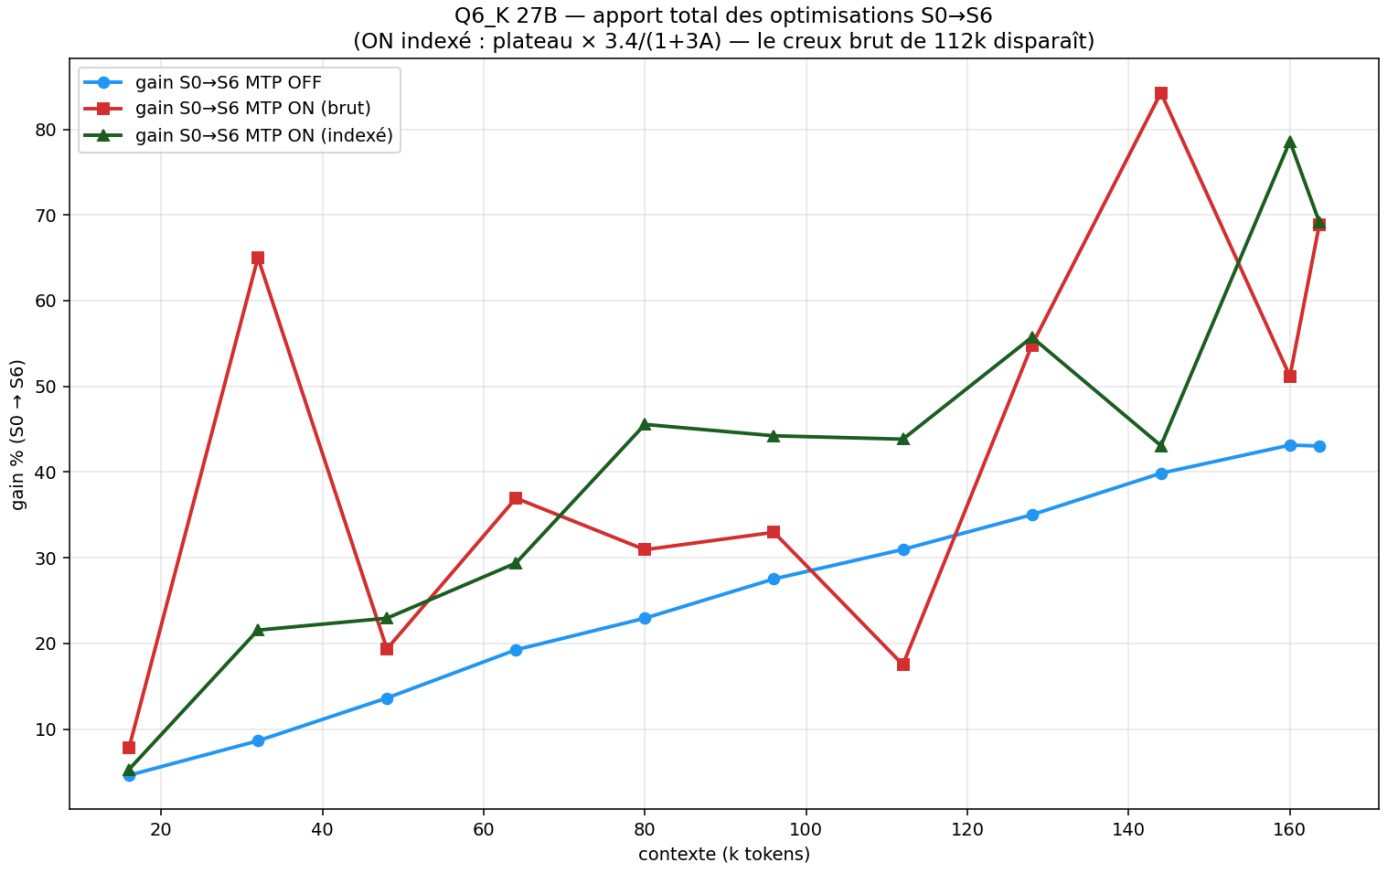
t/s_indexé = plateau × 3,4/(1+3A). Avec t/s = (1+3A)/t_step (validé à ±0,007 sur les 77 runs), c'est ≈ t_step : la vitesse du pas de vérification, indépendante de l'acceptance. À 112k le creux disparaît : le gain S0→S6 passe de +18 % brut à +44 % indexé et l'axe 96k→144k devient lisse (+44…+56 %). Les états S2→S6 se resserrent à ±3 %. Courbe dérivée (égalisation) — elle ne remplace pas les mesures brutes.

Prefill — MTP OFF (froid, 1er passage)



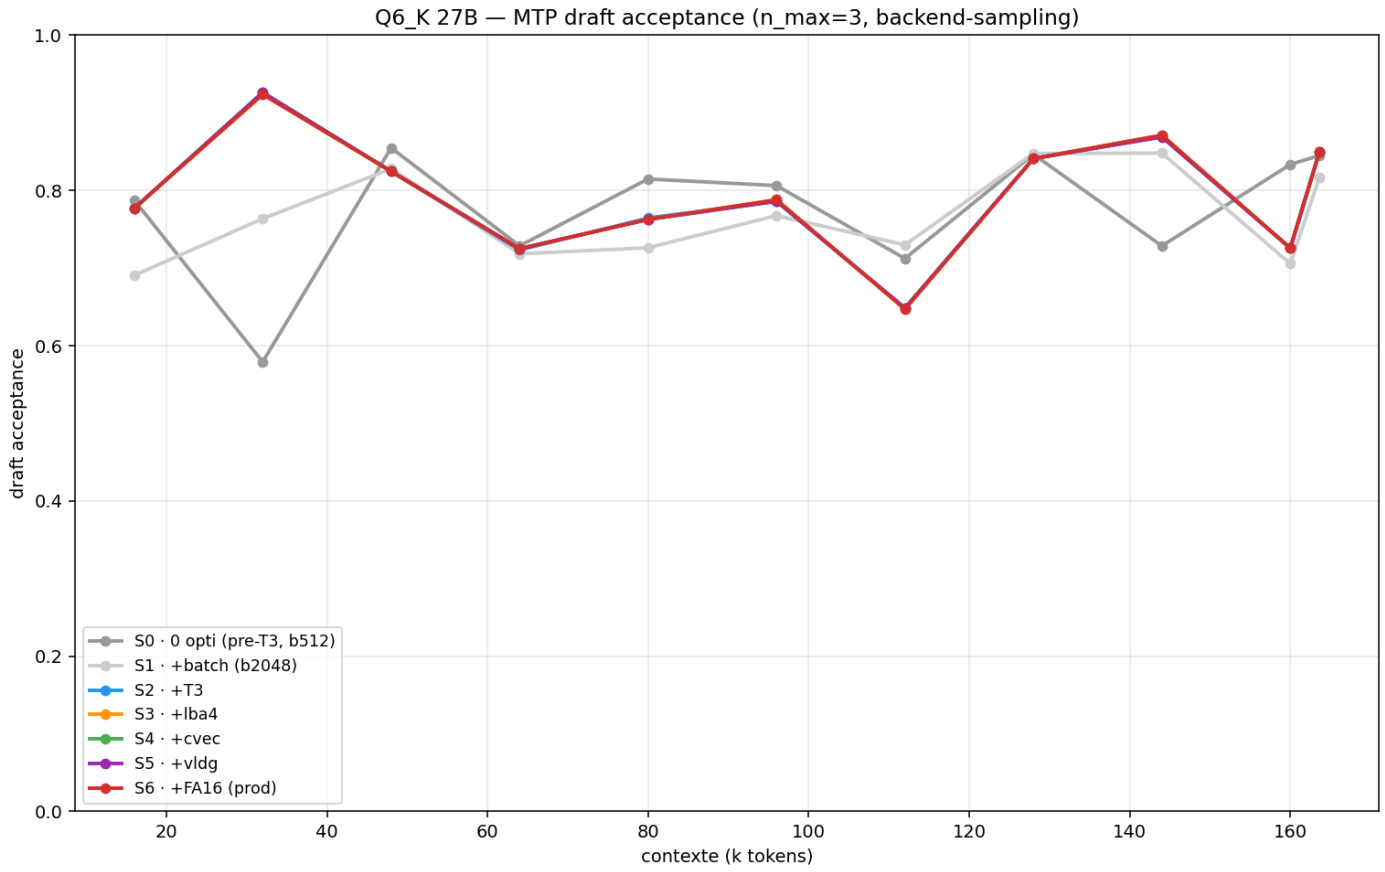
Deux leviers seulement : batch 512→2048 (+9…+19 %, plus fort en bas d'axe) et FA16 compact (+4…+24 %, croît avec le contexte). S2→S5 se superposent (T3/lba4/cvec/vldg n'y touchent pas).

Apport total des optimisations S0→S6



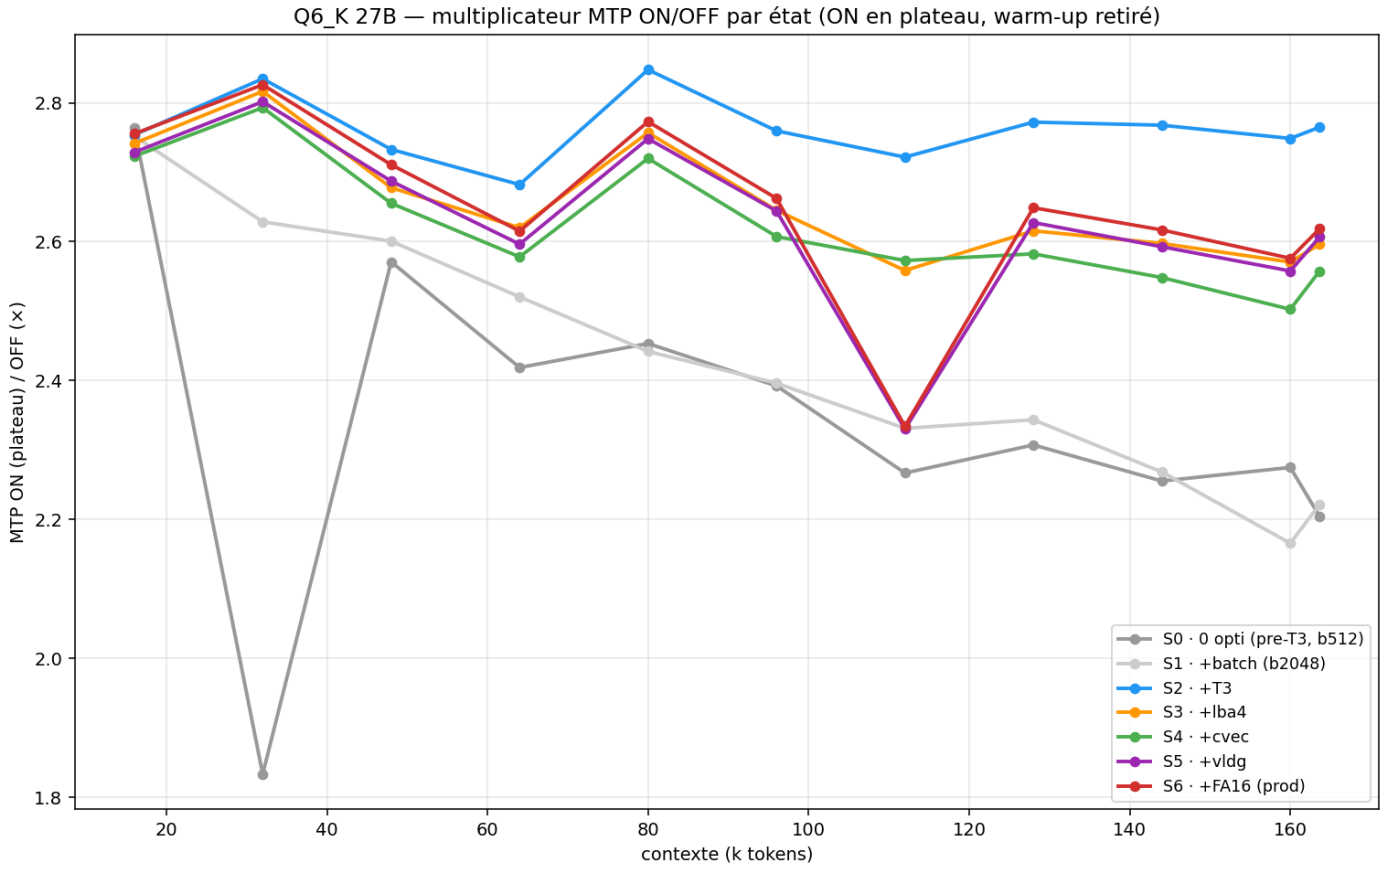
Gain en decode : +4,6 % à 16k → +43,1 % à 160k (OFF). En ON brut le 112k creuse à +18 % (artefact warm-up) ; en ON indexé la courbe suit la tendance et le 112k remonte à +44 %. Le gain s'ouvre avec le contexte — c'est le signal principal de la campagne.

MTP — draft acceptance (n_max=3)



Acceptance stable 0,65–0,93 dès S2 ; bruitée sur S0/S1 (0,58–0,85). Le creux commun à tous les états à 112k (0,65) suit le contenu du prompt, pas une opti.

MTP — multiplicateur ON/OFF par état (ON en plateau)



Multiplicateur ON(plateau)/OFF : 2,6–2,8× stable sur S2→S6 ; le multiplicateur ON brut était creusé à 112k par le warm-up, pas par l'acceptance. Creux résiduel de 112k sur S6 (×2,33) — effet contenu de l'acceptance (0,65), commun à tous les états.

Chiffrage — decode MTP OFF (t/s, régime établi)

état	16k	32k	48k	64k	80k	96k	112k	128k	144k	160k	164k*
S0	24.3	22.8	21.5	20.0	19.0	18.0	17.2	16.4	15.5	14.9	14.9
S1	24.3	22.8	21.5	20.0	18.9	18.0	17.2	16.4	15.5	14.9	14.9
S2	25.2	24.3	23.5	22.7	21.8	21.2	20.6	20.0	19.3	18.7	18.7
S3	25.3	24.4	24.0	23.2	22.5	22.1	21.4	21.1	20.5	20.0	20.0
S4	25.6	24.9	24.5	23.8	23.2	22.9	22.3	22.0	21.5	21.0	21.0
S5	25.7	25.0	24.6	24.1	23.5	23.2	22.7	22.4	21.9	21.5	21.4
S6	**25.4**	**24.8**	**24.4**	**23.9**	**23.3**	**23.0**	**22.5**	**22.2**	**21.7**	**21.3**	**21.3**

* point haut 167 568 tok (163,6k). S6 = configuration prod actuelle.

Chiffrage — prefill MTP OFF (t/s, froid)

état	16k	32k	48k	64k	80k	96k	112k	128k	144k	160k	164k*
S0	**876**	**813**	**745**	**687**	**638**	**595**	**557**	**524**	**494**	**468**	**463**
S1	**1042**	**945**	**856**	**779**	**716**	**663**	**617**	**577**	**542**	**512**	**505**
S2	**1044**	**945**	**855**	**780**	**717**	**663**	**617**	**577**	**542**	**511**	**505**
S3	**1042**	**944**	**854**	**779**	**715**	**661**	**616**	**576**	**541**	**510**	**504**
S4	**1040**	**943**	**853**	**778**	**715**	**661**	**616**	**576**	**541**	**510**	**504**
S5	**1041**	**943**	**853**	**778**	**715**	**661**	**615**	**575**	**541**	**510**	**504**
S6	**1082**	**1016**	**947**	**884**	**829**	**780**	**737**	**696**	**664**	**633**	**626**

Gains par palier — decode MTP OFF (%)

palier	16k	32k	48k	64k	80k	96k	112k	128k	144k	160k	164k*
S0→S1 batch	**0.2**	**0.0**	**0.0**	**0.0**	**-0.1**	**-0.1**	**0.0**	**0.0**	**-0.1**	**0.0**	**0.0**
S1→S2 T3	**3.6**	**6.5**	**9.3**	**13.4**	**15.1**	**17.5**	**19.7**	**21.6**	**24.4**	**25.9**	**25.8**
S2→S3 lba4	**0.3**	**0.4**	**2.0**	**2.3**	**3.0**	**4.3**	**4.3**	**5.7**	**6.3**	**6.6**	**6.7**
S3→S4 cvec	**1.3**	**1.9**	**2.1**	**2.7**	**3.3**	**3.6**	**4.1**	**4.3**	**4.9**	**5.4**	**5.4**
S4→S5 vldg	**0.3**	**0.6**	**0.7**	**1.1**	**1.3**	**1.3**	**1.6**	**1.6**	**1.8**	**2.0**	**1.9**
S5→S6 FA16	**-1.0**	**-0.9**	**-0.9**	**-0.9**	**-0.9**	**-0.8**	**-0.8**	**-0.8**	**-0.8**	**-0.7**	**-0.7**
S0→S6 total	**4.6**	**8.6**	**13.6**	**19.3**	**22.9**	**27.5**	**31.0**	**35.0**	**39.9**	**43.1**	**43.0**

Chiffrage — decode MTP ON (t/s)

état	16k	32k	48k	64k	80k	96k	112k	128k	144k	160k	164k*
S0 brut	**64.9**	**42.4**	**55.1**	**43.4**	**46.5**	**42.0**	**36.5**	**37.9**	**30.8**	**33.1**	**32.8**
S1 brut	**51.2**	**59.1**	**55.7**	**43.5**	**43.5**	**38.6**	**36.6**	**38.5**	**35.2**	**25.4**	**32.5**
S2 brut	**69.4**	**68.9**	**64.1**	**58.5**	**61.5**	**58.3**	**41.1**	**55.3**	**53.1**	**46.9**	**51.6**
S3 brut	**69.2**	**68.8**	**64.0**	**58.5**	**61.3**	**58.2**	**41.3**	**55.1**	**53.0**	**46.7**	**51.3**
S4 brut	**69.7**	**69.5**	**64.8**	**58.9**	**58.8**	**54.6**	**42.6**	**56.8**	**54.8**	**49.8**	**53.6**

état	16k	32k	48k	64k	80k	96k	112k	128k	144k	160k	164k*
S5 brut	70.1	70.1	65.7	59.9	60.9	56.1	43.9	58.7	56.8	51.1	55.8
S6 brut	69.9	70.0	65.8	59.5	60.8	55.9	42.9	58.7	56.8	50.0	55.3
—	—	—	—	—	—	—	—	—	—	—	—
S0 plat.	67.2	41.9	55.3	48.4	46.5	43.1	38.9	37.9	35.0	33.9	32.8
S1 plat.	67.0	60.0	55.9	50.4	46.3	43.2	40.0	38.5	35.2	32.2	33.0
S2 plat.	69.4	68.9	64.2	60.8	62.1	58.4	56.0	55.4	53.4	51.5	51.7
S3 plat.	69.3	68.8	64.2	60.8	62.0	58.4	54.9	55.2	53.3	51.3	51.8
S4 plat.	69.7	69.5	65.0	61.4	63.2	59.6	57.4	56.8	54.8	52.7	53.8
S5 plat.	70.1	70.1	66.2	62.5	64.6	61.3	52.8	58.7	56.8	54.9	55.9
S6 plat.	70.0	70.1	66.2	62.4	64.6	61.2	52.5	58.7	56.8	54.9	55.7

brut = médiane toutes fenêtres R2 (inclut le warm-up MTP) · plat. = médiane des 6 dernières fenêtres (warm-up retiré). S0/S1 : le brut est de plus à prendre avec prudence (acceptance instable pré-T3).

Chiffrage — decode MTP ON INDEXÉ à acceptance 0,8 (t/s, dérivé)

état	16k	32k	48k	64k	80k	96k	112k	128k	144k	160k	164k*
S0	67.9	52.0	52.7	51.6	45.9	42.9	42.2	36.4	37.4	32.9	31.5
S1	74.1	62.0	54.6	54.3	49.5	44.4	42.7	36.9	33.8	35.2	32.5
S2	70.9	62.0	62.9	65.2	64.1	59.1	64.6	53.4	50.3	55.1	49.5
S3	70.7	62.0	62.8	65.1	64.1	59.0	63.4	53.3	50.2	54.9	49.6
S4	71.2	62.5	63.6	65.7	65.3	60.4	66.3	54.8	51.7	56.4	51.5
S5	71.5	63.1	64.8	66.9	66.8	62.0	61.0	56.7	53.5	58.7	53.5
S6	71.5	63.2	64.8	66.8	66.8	61.8	60.7	56.7	53.5	58.7	53.3

indexé = plateau × 3,4/(1+3A) ≈ t_step : vitesse du pas de vérification si tous les états avaient l'acceptance 0,8. Courbe dérivée (égalisation des comparaisons), pas une mesure.

Gain S0→S6 en decode MTP ON (%) — brut vs indexé

ctx	gain brut	gain indexé
16k	7.8	5.3
32k	65.0	21.6
48k	19.4	22.9
64k	37.0	29.4
80k	30.9	45.6
96k	33.0	44.2
112k	17.5	43.8
128k	54.8	55.7
144k	84.3	43.1
160k	51.2	78.6
164k*	68.9	69.2

Le creux brut de 112k (+18 %) est un artefact du warm-up MTP : indexé, le 112k remonte à +44 % et l'axe 96k→144k devient lisse.

Acceptance MTP (ON) et multiplicateur ON/OFF (×, ON en plateau)

état	16k	32k	48k	64k	80k	96k	112k	128k	144k	160k	164k*
S0 acc	0.79	0.58	0.85	0.73	0.81	0.81	0.71	0.85	0.73	0.83	0.85
S1 acc	0.69	0.76	0.83	0.72	0.73	0.77	0.73	0.85	0.85	0.71	0.82
S2 acc	0.78	0.93	0.82	0.72	0.76	0.79	0.65	0.84	0.87	0.73	0.85
S3 acc	0.78	0.92	0.82	0.72	0.76	0.79	0.65	0.84	0.87	0.73	0.85
S4 acc	0.78	0.93	0.82	0.72	0.76	0.79	0.65	0.84	0.87	0.73	0.85
S5 acc	0.78	0.93	0.82	0.72	0.76	0.79	0.65	0.84	0.87	0.73	0.85
S6 acc	0.78	0.92	0.82	0.72	0.76	0.79	0.65	0.84	0.87	0.73	0.85

état	16k	32k	48k	64k	80k	96k	112k	128k	144k	160k	164k*
S0 ×	2.76	1.83	2.57	2.42	2.45	2.39	2.27	2.31	2.26	2.27	2.20
S1 ×	2.75	2.63	2.60	2.52	2.44	2.40	2.33	2.34	2.27	2.17	2.22
S2 ×	2.75	2.83	2.73	2.68	2.85	2.76	2.72	2.77	2.77	2.75	2.76
S3 ×	2.74	2.82	2.68	2.62	2.76	2.65	2.56	2.62	2.60	2.57	2.60
S4 ×	2.72	2.79	2.66	2.58	2.72	2.61	2.57	2.58	2.55	2.50	2.56
S5 ×	2.73	2.80	2.69	2.60	2.75	2.64	2.33	2.63	2.59	2.56	2.61
S6 ×	2.76	2.83	2.71	2.62	2.77	2.66	2.33	2.65	2.62	2.58	2.62

Lecture synthétique

- Batch 512→2048 : 0 % en decode — c'est un levier purement prefill (+9…+19 %).
- T3 : le cliff dominant en decode, +3,6 % (16k) → +25,9 % (160k). À long contexte T3 représente ~60 % du delta total S0→S6. Le cliff est réel mais continué : lba4 (+0,3…+6,7 %), cvec (+1,3…+5,4 %) et vldg (+0,3…+2,0 %) prolongent la montée après T3 — le saut est compensé par la suite, la courbe S0→S6 ne plate jamais.
- FA16 compact : neutre en decode (−0,7…−1,0 %), +4…+24 % en prefill (croît avec le contexte). En synthèse : prefill = batch + FA16.
- MTP : multiplicateur ON(plateau)/OFF 2,6–2,8× stable sur S2→S6. Le « creux de 112k » de la courbe ON brute est un artefact de mesure : le warm-up MTP (les ~1200 premiers tok générés sont lents, l'acceptance monte) couvrait 11–14 des 15–26 fenêtres R2 à 112k → la médiane toutes fenêtres était tirée vers le bas. En plateau (6 dernières fenêtres) il retombe (S6 : 42,9 → 52,5 t/s) ; indexé à acceptance 0,8 le gain S0→S6 y remonte à +44 % (vs +18 % brut) et l'axe 96k→144k est lisse. Reste un vrai creux d'acceptance à 112k (0,65 vs 0,84 à 128k, commun à tous les états) → effet contenu du prompt.
- Total S0→S6 en decode : +4,6 % à 16k → +43,1 % à 160k ; en prefill +24 % à 160k. T3 ≈ 2/3 du gain à long contexte.

Réserves

- Méthode ON en plateau = médiane des 6 dernières fenêtres R2 — justification : séquences de fenêtres 3s montrant un warm-up MTP (~1200 tok lents) sur presque tous les runs ON ; à 112k le warm-up couvrait 11–14 fenêtres sur 15–26, d'où le creux de la médiane brute.
- MTP ON sur S0/S1 (7 points × 2 états) : le plateau est déjà bien aligné avec S2+, mais les 112k S0/S1 n'ont que 20 fenêtres et l'acceptance y reste instable — à re-mesurer si on veut des chiffres ON fiables avant T3. Les courbes OFF restent la base solide.
- Le point haut 164k* est un point unique sans répétition (limite dure -c 170000 avec les 2048 tok générés).
- Prefill mesuré à froid (1er passage) — sensible à la page cache ; les écarts inter-états y sont de tout façon < 1 % hors batch/FA16.

Artefacts

- bench/data/sweep_q6_170k.jsonl — 158 records (154 points + 4 re-mesures S6/off)
- plot_q6_170k.py — régénère les 8 graphiques de charts/ (dont decode_on_plateau.png et decode_on_norm.png, courbes dérivées plateau / indexé à acc 0,8).
- make_pdf.py — régénère ce PDF depuis sweep.jsonl.
- server.log — log serveur complet de la campagne (source des prompt_tokens et de l'acceptance).